

โจทย์ข้อที่ 1.1

บริษัทขายไอศกรีมต้องการทำนายยอดขาย (ถ้วย) จากอุณหภูมิสูงสุดของวัน (องศาเซลเซียส) โดยมีข้อมูล

5 วัน

ล่าสุดดังนี้

อุณหภูมิ (X)	ยอดขาย (Y)
25	150
30	200
32	230
28	180
35	250

คำสั่ง:

1. จงหาสมการ Linear Regression ($y=mx+c$) จากข้อมูลข้างต้น

$$\hat{a}_{xy} = (3*1.5) + (5*2) + (2*1) + (6*3) + (4*2.2) + (7*3.5) = 67.8$$

$$\hat{a}_x = 25 + 30 + 32 + 28 + 35 = 150$$

$$\hat{a}_{x^2} = 25^2 + 30^2 + 32^2 + 28^2 + 35^2 = 4558$$

$$\bar{x} = \frac{25 + 30 + 32 + 28 + 35}{5} = 30$$

$$\hat{a}_y = 150 + 200 + 230 + 180 + 250 = 1010$$

$$\bar{y} = \frac{(150 + 200 + 230 + 180 + 250)}{5} = 202$$

$$m = \frac{5(30,900) - (150*1010)}{5(4558) - (150)^2} = \frac{300}{29} = 10.3448$$

$$c = 202 - (10.3448 * 30) = -108.3448$$

Ans: $y = 10.3448 * x - 108.3448$

2. ถ้าวันนี้อุณหภูมิ 33 องศาเซลเซียส คาดว่าจะขายไอศกรีมได้กี่ถุง?

$$10.3448 * 33 - 108.3448 = 233.0342$$

Ans: คาดว่าจะขายไอศกรีมได้ 233.0342 ถุง

โจทย์ข้อที่ 1.2

ฟิตเนสแห่งหนึ่งต้องการวิเคราะห์ความสัมพันธ์ระหว่างจำนวนชั่วโมงที่ลูกค้าออกกำลังกายต่อสัปดาห์ (X) กับน้ำหนักที่ลดลงในหนึ่งเดือน (กก.) (Y)

ชั่วโมง/สัปดาห์ (X)	น้ำหนักที่ลด (Y)
3	1.5
5	2.0
2	1.0
6	3.0
4	2.2
7	3.5

คำสั่ง:

1. จงหาสมการ Linear Regression

$$\hat{a} \ xy = (3 * 1.5) + (5 * 2) + (2 * 1) + (6 * 3) + (4 * 2.2) + (7 * 3.5) = 67.8$$

$$\hat{a} \ x = 3 + 5 + 2 + 6 + 4 + 7 = 27$$

$$\hat{a} \ x^2 = 3^2 + 5^2 + 2^2 + 6^2 + 4^2 + 7^2 = 139$$

$$\bar{x} = \frac{3 + 5 + 2 + 6 + 4 + 7}{6} = 4.5$$

$$\hat{a} \ y = 1.5 + 2 + 1 + 3 + 2.2 + 3.5 = 13.2$$

$$\hat{y} = \frac{(1.5 + 2 + 1 + 3 + 2.2 + 3.5)}{6} = 2.2$$

$$m = \frac{6(67.8) - (27 * 13.2)}{6(139) - (27)^2} = \frac{50.4}{105} = 0.48$$

$$c = 2.2 - (0.48 * 4.5) = 0.04$$

Ans: $y = 0.48 * x + 0.04$

2. หากลูกค้าออกกำลังกาย 8 ชั่วโมง/สัปดาห์ คาดว่าหนักจะลดลงกี่กิโลกรัม?

$$0.48 * 8 + 0.04 = 3.88$$

Ans: คาดว่าหนักจะลดลง 4.24 กิโลกรัม

โจทย์ข้อที่ 2.1

ต้องการสร้างโมเดลทำนาย "ราคามือสอง" (Y, หน่วยเป็นพันบาท) ของสมาร์ทโฟน โดยพิจารณาจาก "อายุการใช้งาน (เดือน)" (X1)

อายุ (X1)	ราคา (Y)
6	18
12	14
24	9
8	17
18	11

คำสั่ง: จงทำการแบ่งครึ่งแรก (First Split) ที่ดีที่สุด โดยคำนวณค่า Standard Deviation Reduction (SDR) ของทุกจุดแบ่งที่เป็นไปได้

$$\bar{y} = 18 + 14 + 9 + 17 + 11 = 69$$

$$\bar{y} = \frac{18 + 14 + 9 + 17 + 11}{5} = 13.8$$

$$SD = 1712.409$$

$$SD = 3.4293$$

Unique X

$$(6+8)/2=7$$

$$(8+12)/2=10$$

$$(12+18)/2=15$$

$$(18+24)/2=21$$

X<=7

$$L(y):\{18\}$$

$$w_L = 1, SD_L = 0$$

$$R(y):\{14, 9, 17, 11\}$$

$$w_R = 4, \bar{y}_R = 3.571, SD_R = 3.031$$

$$SDR = 3.429 - \frac{\frac{1}{5} * 0.5 + \frac{1}{5} * 3.031}{4} = 1.004$$

X<=10

$$L(y):\{18, 17\}$$

$$w_L = 2, \bar{y}_L = 17.5, SD_L = 0.5$$

$$R(y):\{14, 9, 11\}$$

$$w_R = 3, \bar{y}_R = 11.333, SD_R = 2.055$$

$$SDR = 3.429 - \frac{\frac{1}{5} * 0.5 + \frac{1}{5} * 2.055}{4} = 1.996$$

X<=15

$$L(y):\{18, 17, 14\}$$

$$w_L = 3, \bar{y}_L = 16.333, SD_L = 1.7$$

$$R(y):\{9, 11\}$$

$$w_R = 2, \bar{y}_R = 10, SD_R = 1$$

$$SDR = 3.429 - \frac{\frac{1}{5} * 1.7 + \frac{1}{5} * 1}{4} = 2.009$$

X<=21

$$L(y):\{18, 17, 14, 11\}$$

$$w_L = 4, \bar{y}_L = 15, SD_L = 2.739$$

$$R(y):\{9\}$$

$$w_R = 1, SD_R = 0$$

$$SDR = 3.429 - \frac{\frac{1}{5} * 2.739 + \frac{1}{5} * 0}{4} = 1.238$$

Ans: ที่ดีที่สุดคือ $X \leq 15$

$$L(y): \{18, 17, 14\}$$

$$w_L = 3, \bar{y}_L = 16.333, SD_L = 1.7$$

$$R(y): \{9, 11\}$$

$$w_R = 2, \bar{y}_R = 10, SD_R = 1$$

$$SDR = 3.429 - \frac{\frac{1}{3} * 1.7^2 + \frac{2}{5} * 1^2}{\frac{5}{8}} = 2.009$$

โจทย์ข้อที่ 2.2 (โจทย์ท้าทาย)

บริษัทเกมต้องการสร้างโมเดลทำนาย "คะแนนในเกม" (Y) ของผู้เล่น โดยอ้างอิงจาก "ชั่วโมงที่เล่น" (X1) และ "เลเวลผู้เล่น" (X2) เนื่องจาก หยุดแบ่ง Node (สร้าง Leaf) ก็ต่อเมื่อ Node นั้นมีข้อมูลน้อยกว่าหรือเท่ากับ 3 ชิ้น

ชั่วโมงที่เล่น (X1)	เลเวลผู้เล่น (X2)	คะแนนในเกม (Y)
5	10	1200
15	25	3500
20	30	4500
2	5	500
8	15	1800
25	40	6000
12	20	2800
18	35	4000

1. จงสร้าง Decision Tree จากข้อมูลทั้งหมดให้สมบูรณ์ตามขั้นตอน (แสดงการคำนวณเพื่อหาจุดแบ่งที่ดี

ที่สุดในแต่ละ Node)

$$\bar{y} = \frac{1200 + 3500 + 4500 + 500 + 1800 + 6000 + 2800 + 4000}{8} = 3037.5$$

$$SD = \sqrt{\frac{(1200 - 3037.5)^2 + (3500 - 3037.5)^2 + (4500 - 3037.5)^2 + (500 - 3037.5)^2 + (1800 - 3037.5)^2 + (6000 - 3037.5)^2 + (2800 - 3037.5)^2 + (4000 - 3037.5)^2}{8}}$$

$$SD = 1712.409$$

$$\begin{aligned}
 \text{UniqueX1} \\
 (2+5)/2 &= 3.5 \\
 (5+8)/2 &= 6.5 \\
 (8+12)/2 &= 10 \\
 (12+15)/2 &= 13.5 \\
 (15+18)/2 &= 16.5 \\
 (18+20)/2 &= 19 \\
 (20+25)/2 &= 22.5
 \end{aligned}$$

$$\begin{aligned}
 \text{UniqueX2} \\
 (5+10)/2 &= 7.5 \\
 (10+15)/2 &= 12.5 \\
 (15+20)/2 &= 17.5 \\
 (20+25)/2 &= 22.5 \\
 (25+30)/2 &= 27.5 \\
 (30+35)/2 &= 32.5 \\
 (35+40)/2 &= 37.5
 \end{aligned}$$

หาจุดแบ่งแรกที่ดีที่สุด

X1<=3.5

$$\begin{aligned}
 L(y) &: \{500\} & R(y) &: \{1200, 3500, 4500, 1800, 6000, 2800, 4000\} \\
 w_L &= 1, SD_L = 0 & w_R &= 7, \bar{y}_R = 3400, SD_R = 1516.575 \\
 SDR &= 1712.409 - \frac{\sum_{i=1}^7 (y_i - \bar{y}_R)^2}{w_R} = 1712.409 - \frac{\sum_{i=1}^7 (y_i - 3400)^2}{7} = 1712.409 - \frac{\sum_{i=1}^7 (y_i - 3400)^2}{7} = 385.406
 \end{aligned}$$

X1<=6.5

$$\begin{aligned}
 L(y) &: \{500, 1200\} & R(y) &: \{3500, 4500, 1800, 6000, 2800, 4000\} \\
 w_L &= 2, \bar{y}_L = 850, SD_L = 350 & w_R &= 6, \bar{y}_R = 3766.667, SD_R = 1319.933 \\
 SDR &= 1712.409 - \frac{\sum_{i=1}^2 (y_i - \bar{y}_L)^2 + \sum_{i=3}^8 (y_i - \bar{y}_R)^2}{w_L + w_R} = 1712.409 - \frac{\sum_{i=1}^2 (y_i - 850)^2 + \sum_{i=3}^8 (y_i - 3766.667)^2}{8} = 634.959
 \end{aligned}$$

X1<=10

$$\begin{aligned}
 L(y) &: \{500, 1200, 1800\} & R(y) &: \{3500, 4500, 6000, 2800, 4000\} \\
 w_L &= 3, \bar{y}_L = 1166.667, SD_L = 531.2459 & w_R &= 5, \bar{y}_R = 4160, SD_R = 1078.147 \\
 SDR &= 1712.409 - \frac{\sum_{i=1}^3 (y_i - \bar{y}_L)^2 + \sum_{i=4}^8 (y_i - \bar{y}_R)^2}{w_L + w_R} = 1712.409 - \frac{\sum_{i=1}^3 (y_i - 1166.667)^2 + \sum_{i=4}^8 (y_i - 4160)^2}{8} = 839.35
 \end{aligned}$$

X1<=13.5

$$\begin{aligned}
 L(y) &: \{500, 1200, 1800, 2800\} & R(y) &: \{3500, 4500, 6000, 4000\} \\
 w_L &= 4, \bar{y}_L = 1575, SD_L = 843.727 & w_R &= 4, \bar{y}_R = 4500, SD_R = 935.414 \\
 SDR &= 1712.409 - \frac{\sum_{i=1}^4 (y_i - \bar{y}_L)^2 + \sum_{i=5}^8 (y_i - \bar{y}_R)^2}{w_L + w_R} = 1712.409 - \frac{\sum_{i=1}^4 (y_i - 1575)^2 + \sum_{i=5}^8 (y_i - 4500)^2}{8} = 822.823
 \end{aligned}$$

X1<=16.5

$$\begin{array}{ll} L(y):\{500, 1200, 1800, 2800, 3500\} & R(y):\{4500, 6000, 4000\} \\ w_L = 5, \bar{y}_L = 1960, SD_L = 1069.626 & w_R = 3, \bar{y}_R = 4833.333, SD_R = 849.837 \\ SDR = 1712.409 - \frac{\frac{eas}{8} * 1069.626}{\frac{eas}{8}} + \frac{\frac{as}{8} * 849.837}{\frac{as}{8}} = 725.204 & \end{array}$$

X1<=19

$$\begin{array}{ll} L(y):\{500, 1200, 1800, 2800, 3500, 4000\} & R(y):\{4500, 6000\} \\ w_L = 6, \bar{y}_L = 2300, SD_L = 1226.784 & w_R = 2, \bar{y}_R = 5250, SD_R = 750 \\ SDR = 1712.409 - \frac{\frac{eas}{8} * 1226.784}{\frac{eas}{8}} + \frac{\frac{as}{8} * 750}{\frac{as}{8}} = 604.821 & \end{array}$$

X1<=22.5

$$\begin{array}{ll} L(y):\{500, 1200, 1800, 2800, 3500, 4500\} & R(y):\{6000\} \\ w_L = 7, \bar{y}_L = 2614.286, SD_L = 1385.051 & w_R = 1, SD_R = 0 \\ SDR = 1712.409 - \frac{\frac{eas}{8} * 1385.051}{\frac{eas}{8}} + \frac{\frac{as}{8} * 0}{\frac{as}{8}} = 500.489 & \end{array}$$

X2<=3.5

$$\begin{array}{ll} L(y):\{500\} & R(y):\{1200, 3500, 4500, 1800, 6000, 2800, 4000\} \\ w_L = 1, SD_L = 0 & w_R = 7, \bar{y}_R = 3400, SD_R = 1516.575 \\ SDR = 1712.409 - \frac{\frac{eas}{8} * 0}{\frac{eas}{8}} + \frac{\frac{as}{8} * 1516.575}{\frac{as}{8}} = 385.406 & \end{array}$$

X2<=12.5

$$\begin{array}{ll} L(y):\{500, 1200\} & R(y):\{3500, 4500, 1800, 6000, 2800, 4000\} \\ w_L = 2, \bar{y}_L = 850, SD_L = 350 & w_R = 6, \bar{y}_R = 3766.667, SD_R = 1319.933 \\ SDR = 1712.409 - \frac{\frac{eas}{8} * 843.727}{\frac{eas}{8}} + \frac{\frac{as}{8} * 1319.933}{\frac{as}{8}} = 634.959 & \end{array}$$

X2<=17.5

$$\begin{array}{ll} L(y):\{500, 1200, 1800\} & R(y):\{3500, 45 \\ w_L = 3, \bar{y}_L = 1166.667, SD_L = 531.2459 & 00, 6000, 2800, 4000\} \end{array}$$

$$w_R = 5, \bar{y}_R = 4160, SD_R = 1078.147$$

$$SDR = 1712.409 - \frac{\bar{y}_L}{8} * 531.246 + \frac{\bar{y}_R}{8} * 1078.147 = 839.35$$

X2<=22.5

$$L(y):\{500, 1200, 1800, 2800\} \quad R(y):\{3500, 4500, 6000, 4000\}$$

$$w_L = 4, \bar{y}_L = 1575, SD_L = 843.727 \quad w_R = 4, \bar{y}_R = 4500, SD_R = 935.414$$

$$SDR = 1712.409 - \frac{\bar{y}_L}{8} * 843.727 + \frac{\bar{y}_R}{8} * 935.414 = 822.823$$

X2<=27.5

$$L(y):\{500, 1200, 1800, 2800, 3500\} \quad R(y):\{4500, 6000, 4000\}$$

$$w_L = 5, \bar{y}_L = 1960, SD_L = 1069.626 \quad w_R = 3, \bar{y}_R = 4833.333, SD_R = 849.837$$

$$SDR = 1712.409 - \frac{\bar{y}_L}{8} * 1069.626 + \frac{\bar{y}_R}{8} * 849.837 = 725.204$$

X2<=32.5

$$L(y):\{500, 1200, 1800, 2800, 3500, 4000\} \quad R(y):\{4000, 6000\}$$

$$w_L = 6, \bar{y}_L = 2383.333, SD_L = 1287.788 \quad w_R = 2, \bar{y}_R = 5000, SD_R = 1000$$

$$SDR = 1712.409 - \frac{\bar{y}_L}{8} * 1287.788 + \frac{\bar{y}_R}{8} * 1000 = 496.568$$

X2<=37.5

$$L(y):\{500, 1200, 1800, 2800, 3500, 4500\} \quad R(y):\{6000\}$$

$$w_L = 7, \bar{y}_L = 2614.286, SD_L = 1385.051 \quad w_R = 1, SD_R = 0$$

$$SDR = 1712.409 - \frac{\bar{y}_L}{8} * 1385.051 + \frac{\bar{y}_R}{8} * 0 = 500.489$$

การแบ่งกลุ่มแรกที่ดีที่สุดคือ X1<=10 และ X2<=17.5

$$L(y):\{500, 1200, 1800\} \quad R(y):\{3500, 4500\}$$

$$w_L = 3, \bar{y}_L = 1166.667, SD_L = 531.2459$$

$$00, 6000, 2800, 4000\}$$

$$w_R = 5, \bar{y}_R = 4160, SD_R = 1078.147$$

$$SDR = 1712.409 - \frac{\frac{531.246}{8} * 531.246}{\frac{1078.147}{8} * 1078.147} = 839.35$$

จะได้

กลุ่มข้อมูล(L)

ชั่วโมงที่เล่น(x1)	เวลา(x2)	คะแนน(y)
2	5	500
5	10	1200
8	15	1800

กลุ่มข้อมูล(R)

ชั่วโมงที่เล่น(x1)	เวลา(x2)	คะแนน(y)
12	20	2800
15	25	3500
18	35	4000
20	30	4500
25	40	6000

หยดแบ่ง Node (สร้าง Leaf) ก็ต่อเมื่อ Node นั้นมีข้อมูลน้อยกว่าหรือเท่ากับ 3 ชิ้น

หาจุดแบ่งที่สองที่ดีที่สุดจากกลุ่มข้อมูล(L)

UniqueX1

$$(12+15)/2=13.5$$

$$(15+18)/2=16.5$$

$$(18+20)/2=19$$

$$(20+25)/2=22.5$$

UniqueX2

$$(20+25)/2=22.5$$

$$(25+30)/2=27.5$$

$$(30+35)/2=32.5$$

$$(35+40)/2=37.5$$

$$\bar{y} = \frac{2800 + 3500 + 4000 + 4500 + 6000}{5} = 4160$$

$$SD = \sqrt{\frac{(2800 - 4160)^2 + (3500 - 4160)^2 + (4000 - 4160)^2 + (4500 - 4160)^2 + (6000 - 4160)^2}{5}}$$

$$SD = 1078.147$$

X1<=13.5

L(y):{2800}

$$w_L = 1, SD_L = 0$$

R(y):{3500,4000,4500,6000}

$$w_R = 5, \bar{y}_R = 2760, SD_R = 1177.455$$

$$SDR = 1078.148 - \frac{1}{5} * 0 + \frac{4}{5} * 1177.455 = 329.816$$

X1<=16.5

L(y):{2800,3500}

$$w_L = 2, \bar{y}_L = 3150, SD_L = 350$$

R(y):{4000,4500,6000}

$$w_R = 4, \bar{y}_R = 4833.333, SD_R = 849.837$$

$$SDR = 1078.147 - \frac{2}{5} * 350 + \frac{3}{5} * 849.837 = 428.245$$

X1<=19

L(y):{2800,3500,4000}

w_L=3, y_L=3433.333, SD_L=492.161

$$SDR = 1078.147 - \frac{\frac{492.161}{492.161} * 492.161}{\frac{492.161}{492.161}} + \frac{\frac{750}{750} * 750}{\frac{750}{750}} = 259.578$$

R(y):{4500,6000}

w_R=4, y_R=5250, SD_R=750

X1<=22.5

L(y):{2800,3500,4000,4500}

w_L=4, y_L=3700, SD_L=628.49

$$SDR = 1078.147 - \frac{\frac{492.161}{492.161} * 492.161}{\frac{492.161}{492.161}} + \frac{\frac{750}{750} * 750}{\frac{750}{750}} = 575.335$$

R(y):{ 6000}

w_R=1, SD_R=0

X2<=22.5

L(y):{2800}

w_L=1, SD_L=0

$$SDR = 1078.148 - \frac{\frac{0}{0} * 0}{\frac{0}{0}} + \frac{\frac{1177.455}{1177.455} * 1177.455}{\frac{1177.455}{1177.455}} = 329.816$$

R(y):{3500,4000,4500,6000}

w_R=5, y_R=2760, SD_R=1177.455

X2<=27.5

L(y):{2800,3500}

w_L=2, y_L=3150, SD_L=350

$$SDR = 1078.147 - \frac{\frac{350}{350} * 350}{\frac{350}{350}} + \frac{\frac{849.837}{849.837} * 849.837}{\frac{849.837}{849.837}} = 428.245$$

R(y):{4000,4500,6000}

w_R=4, y_R=4833.333, SD_R=849.837

X2<=32.5

L(y):{2800,3500,4500}

w_L=3, y_L=3600, SD_L=697.615

$$SDR = 1078.147 - \frac{\frac{697.615}{697.615} * 697.615}{\frac{697.615}{697.615}} + \frac{\frac{1000}{1000} * 1000}{\frac{1000}{1000}} = 259.578$$

R(y):{4000,6000}

w_R=4, y_R=5000, SD_R=1000

X2<=37.5

L(y):{2800,3500,4000,4500} R(y):{6000}

w_L=4, ȳ_L=3700, SD_L=628.49 w_R=1, SD_R=0

$$SDR = 1078.147 - \frac{\frac{492.161}{\bar{y}_L} + \frac{750}{\bar{y}_R}}{4} = 575.335$$

การแบ่งกลุ่มสองที่ดีที่สุดคือ $X_1 \leq 22.5$ หรือ $X_2 \leq 37.5$

$$L(y): \{2800, 3500, 4000, 4500\} \quad R(y): \{6000\}$$

$$w_L = 4, \bar{y}_L = 3700, SD_L = 628.49 \quad w_R = 1, SD_R = 0$$

$$SDR = 1078.147 - \frac{\frac{4}{5} * 492.161}{\frac{4}{5}} + \frac{\frac{2}{5} * 750}{\frac{1}{5}} = 575.335$$

กลุ่มข้อมูล(L)

ชั้วโมงที่เล่น(x1)	เลเวล(x2)	คะแนน(y)
12	20	2800
15	25	3500
18	35	4000
20	30	4500

กลุ่มข้อมูล(R)

ชั้วโมงที่เล่น(x1)	เลเวล(x2)	คะแนน(y)
25	40	6000

$$\bar{y} = \frac{2800 + 3500 + 4000 + 4500}{4} = 3700$$

$$SD = \sqrt{\frac{(2800 - 3700)^2 + (3500 - 3700)^2 + (4000 - 3700)^2 + (4500 - 3700)^2}{4}}$$

$$SD = 628.49$$

UniqueX1

$$(12+15)/2=13.5$$

$$(15+18)/2=16.5$$

$$(18+20)/2=19$$

UniqueX2

$$(20+25)/2=22.5$$

$$(25+30)/2=27.5$$

$$(30+35)/2=32.5$$

X1<=13.5

L(y):{2800}

w_L=1, SD_L=0

$$SDR = 628.49 - \frac{\hat{e}^2}{\hat{e}^4} * 0 + \frac{\hat{e}^2}{\hat{e}^4} * 408.248 = 322.304$$

R(y):{3500,4000,4500}

w_R=3, ȳ_R=4000, SD_R=408.3248

X1<=16.5

L(y):{2800,3500}

w_L=2, ȳ_L=3150, SD_L=350

$$SDR = 628.49 - \frac{\hat{e}^2}{\hat{e}^4} * 350 + \frac{\hat{e}^2}{\hat{e}^4} * 250 = 328.49$$

R(y):{4000,4500}

w_R=2, ȳ_R=4250, SD_R=250

X1<=19

L(y):{2800,3500,4000}

w_L=3, ȳ_L=3433.333, SD_L=492.161

$$SDR = 628.49 - \frac{\hat{e}^3}{\hat{e}^4} * 492.161 + \frac{\hat{e}^2}{\hat{e}^4} * 0 = 259.369$$

R(y):{4500}

w_R=1, SD_R=0

X2<=22.5

L(y):{2800}

w_L=1, SD_L=0

$$SDR = 628.49 - \frac{\hat{e}^2}{\hat{e}^4} * 0 + \frac{\hat{e}^2}{\hat{e}^4} * 408.248 = 322.304$$

R(y):{3500,4000,4500}

w_R=3, ȳ_R=4000, SD_R=408.3248

X2<=27.5

L(y):{2800,3500}

w_L=2, ȳ_L=3150, SD_L=350

$$SDR = 628.49 - \frac{\hat{e}^2}{\hat{e}^4} * 350 + \frac{\hat{e}^2}{\hat{e}^4} * 250 = 328.49$$

R(y):{4000,4500}

w_R=2, ȳ_R=4250, SD_R=250

$X2 \leq 32.5$

$L(y):\{2800, 3500, 4500\}$

$$w_L = 3, \bar{y}_L = 3433.333, SD_L = 492.161$$

$R(y):\{4000\}$

$$w_R = 1, SD_R = 0$$

$$SDR = 628.49 - \frac{\frac{3}{4} * 697.615}{\frac{1}{4}} + \frac{\frac{1}{4} * 0}{\frac{1}{4}} = 105.279$$

การแบ่งกลุ่มสามที่ดีที่สุดคือ $X1 \leq 16.5$ หรือ $X2 \leq 27.5$

$L(y):\{2800, 3500\}$

$$w_L = 2, \bar{y}_L = 3150, SD_L = 350$$

$R(y):\{4000, 4500\}$

$$w_R = 2, \bar{y}_R = 4250, SD_R = 250$$

$$SDR = 628.49 - \frac{\frac{2}{4} * 350}{\frac{1}{4}} + \frac{\frac{2}{4} * 250}{\frac{1}{4}} = 328.49$$

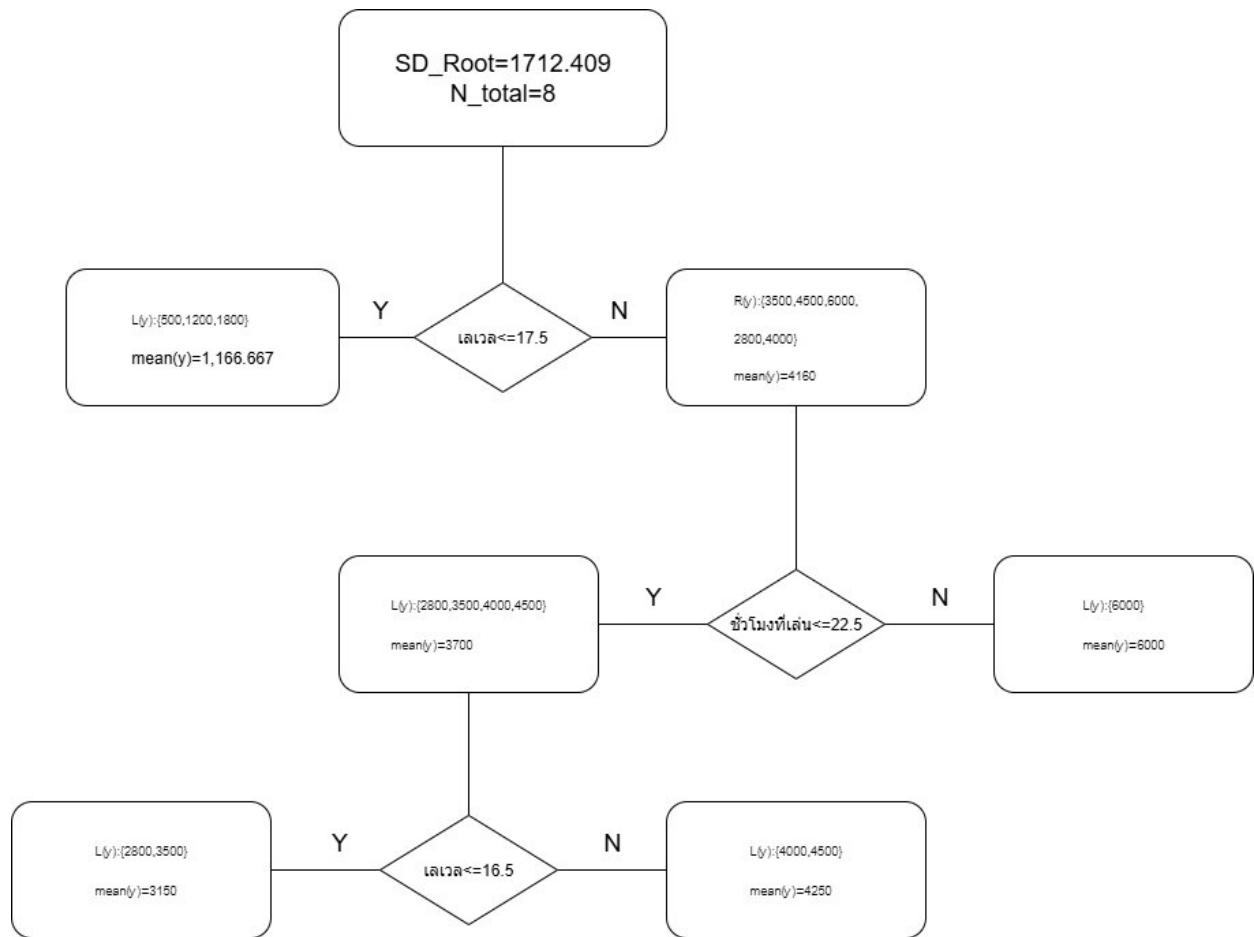
กลุ่มข้อมูล(L)

ชั้วโมงที่เล่น(x1)	เวลา(x2)	คะแนน(y)
12	20	2800
15	25	3500

กลุ่มข้อมูล(R)

ชั้วโมงที่เล่น(x1)	เวลา(x2)	คะแนน(y)
18	35	4000
20	30	4500

2. วิธีการสร้างต้นไม้ (Decision Tree) ที่สร้างเสร็จแล้ว



3. หากมีผู้เล่นใหม่ที่มีชั่วโมงที่เล่น 10 ชั่วโมง และ เลเวล 18 จงทำนายค่าแนวโน้มของเขา

หากมีผู้เล่นใหม่ที่มีชั่วโมงที่เล่น 10 ชั่วโมง และ เลเวล 18 จะมีค่าแนวโน้มอยู่ที่ 4250

โจทย์ข้อที่ 3.1

นักวิเคราะห์สินเชื่อมีข้อมูลการอนุมัติสินเชื่อส่วนบุคคล โดยพิจารณาจาก "รายได้ต่อปี (แสนบาท)" (X_1) และ "หนี้สินรวม (แสนบาท)" (X_2)

ID	รายได้ (X_1)	หนี้สิน (X_2)	ผลอนุมัติ (Y)
P1	5	1	อนุมัติ
P2	6	3	อนุมัติ
P3	2	2	ไม่อนุมัติ
P4	3	4	ไม่อนุมัติ
P5	7	2	อนุมัติ
P6	4	5	ไม่อนุมัติ

คำสั่ง: ลูกค้าใหม่ (P_{new}) มีรายได้ 6 แสนบาท และ หนี้สิน 4 แสนบาท จะใช้ K-NN ($K=3$) ทำนายว่าลูกค้าคนนี้จะได้รับการอนุมัติหรือไม่?

$$P_1 = \sqrt{(5 - 6)^2 + (1 - 4)^2} = 3.162$$

$$P_2 = \sqrt{(6 - 6)^2 + (3 - 4)^2} = 1$$

$$P_3 = \sqrt{(2 - 6)^2 + (2 - 4)^2} = 4.472$$

$$P_4 = \sqrt{(3 - 6)^2 + (4 - 4)^2} = 3$$

$$P_5 = \sqrt{(7 - 6)^2 + (2 - 4)^2} = 2.236$$

$$P_6 = \sqrt{(4 - 6)^2 + (5 - 4)^2} = 2.236$$

จะใช้ K-NN ($K=3$) ทำนายว่าลูกค้าคนนี้จะได้รับการอนุมัติหรือไม่?

ID	ระยะห่างจาก P_{New}	ผลอนุมัติ
P1	1	อนุมัติ
P5, P6	2.236	อนุมัติ/ไม่อนุมัติ
P4	3	ไม่อนุมัติ

\ P_{New} อาจจะอนุมัติหรือไม่อนุมัติก็ได้ ก็ได้ หรืออิงจากระยะทางเฉลี่ยที่สุด

กลุ่มอนุมัติ P1,P5

$$(1+2.236)/2=1.618$$

กลุ่มไม่อนุมัติ P4,P6

$$(3+2.236)/2=2.618$$

\ P_New จะจัดอยู่ในกลุ่มอนุมัติ

โจทย์ข้อที่ 3.2

มหาวิทยาลัยแห่งหนึ่งใช้ข้อมูล "เกรดเฉลี่ยตอน ม.ปลาย" (X1) และ "คะแนนสอบเข้า" (X2) เพื่อคัดกรองนักศึกษาที่มีแนวโน้มจะ "เรียนต่อจนจบ" หรือ "ลาออก"

ID	GPA (X1)	คะแนนสอบ (X2)	สถานะ (Y)
S1	3.8	85	เรียนจบ
S2	2.5	60	ลาออก
S3	3.5	90	เรียนจบ
S4	2.8	75	ลาออก
S5	3.2	80	เรียนจบ
S6	2.2	65	ลาออก
S7	3.9	95	เรียนจบ

คำสั่ง: นักเรียนใหม่ (S_{new}) มีGPA 3.0 และ คะแนนสอบ 70 จะใช้K-NN (K=5) ทำนายสถานะของนักเรียน

ค้นนี้

$$S_1 = \sqrt{(3.8 - 3)^2 + (85 - 70)^2} = 15.021$$

$$S_2 = \sqrt{(2.5 - 3)^2 + (60 - 70)^2} = 10.012$$

$$S_3 = \sqrt{(3.5 - 3)^2 + (90 - 70)^2} = 20.006$$

$$S_4 = \sqrt{(2.8 - 3)^2 + (75 - 70)^2} = 5.004$$

$$S_5 = \sqrt{(3.2 - 3)^2 + (80 - 70)^2} = 10.002$$

$$S_6 = \sqrt{(2.2 - 3)^2 + (65 - 70)^2} = 5.063$$

$$S_7 = \sqrt{(3.9 - 3)^2 + (95 - 70)^2} = 25.016$$

ID	ระยะห่างจากP_New	สถานะ
S4	5.004	ลาออก
S6	5.063	ลาออก
S5	10.002	เรียนจบ
S2	10.012	ลาออก
S1	15.021	เรียนจบ

\ S_New มีแนวโน้มว่าจะเรียนจบ

โจทย์ข้อที่ 4.1

มีข้อมูล 2 คลาส คือ A (สีฟ้า) และ B (สีแดง)

- คลาส A: P1(2, 5), P2(3, 2)
- คลาส B: P3(6, 4), P4(7, 7)

มีคนเสนอเส้นแบ่ง (Hyperplane) H1 คือเส้นแนวตั้ง $x=4.5$

คำสั่ง:

1. จงคำนวณหาระยะห่างจากทุกจุดไปยังเส้น H1

$$\backslash \text{ สมการหลักคือ } 1x + 0y - 4.5 = 0$$

กลุ่ม A

$$P1 = \frac{|2 + 0 - 4.5|}{\sqrt{1^2 + 0^2}} = 2.5$$

$$P2 = \frac{|3 + 0 - 4.5|}{\sqrt{1^2 + 0^2}} = 1.5$$

กลุ่ม B

$$P3 = \frac{|6 + 0 - 4.5|}{\sqrt{1^2 + 0^2}} = 1.5$$

$$P4 = \frac{|7 + 0 - 4.5|}{\sqrt{1^2 + 0^2}} = 2.5$$

2. เส้น H1 มี Support Vectors คือจุดใดบ้าง? และมี Margin กว้างเท่าใด?

\ เส้น H1 มี Support Vectors คือจุด P2 และ P3 และมี Margin = 3

3. จงหาเส้นแบ่งที่ดีที่สุด (Optimal Hyperplane) และ Margin สูงสุดที่เป็นไปได้สำหรับข้อมูลทุกด้าน

$$\backslash X_{\text{optimal}}: \frac{3+6}{2} = 4.5 \text{ และมี Margin = 3}$$

โจทย์ข้อที่ 4.2

จากข้อมูลชุดเดิมในข้อ 4.1 มีคณเสนอเส้นแบ่งใหม่ $H2$ คือ $x+y-8=0$

คำสั่ง:

1. จงคำนวณหาระยะห่างจากทุกจุดไปยังเส้น $H2$

\ สมการหลักคือ $x+y-8=0$

กลุ่ม A

$$P1 = \frac{|2+5-8|}{\sqrt{1^2 + 1^2}} = 0.707$$

$$P2 = \frac{|3+2-8|}{\sqrt{1^2 + 1^2}} = 2.121$$

กลุ่ม B

$$P3 = \frac{|6+4-8|}{\sqrt{1^2 + 1^2}} = 1.414$$

$$P4 = \frac{|7+7-8|}{\sqrt{1^2 + 0^2}} = 6.364$$

2. เส้น $H2$ มี Support Vectors คือจุดใดบ้าง และ Margin กว้างเท่าใด?

\ เส้น $H2$ มี Support Vectors คือจุด $P1$ และ $P3$ และ มี Margin = 2.121

3. เปรียบเทียบกับผลลัพธ์ในข้อ 4.1 เส้น $H2$ เป็นเส้นแบ่งที่ดีที่สุดหรือไม่
เพราะอะไร?

\ เทียบกับ $H1$ และ $H2$ ไม่ใช้เส้นแบ่งที่ดีที่สุด เพราะ $H1$ มี Margin สูงกว่าและมีระยะห่างระหว่างข้อมูลทั้งสองกลุ่มเท่าๆ กัน